



**“AÑO DE LA ESPERANZA Y EL FORTALECIMIENTO DE
LA DEMOCRACIA”**



FACULTAD DE CIENCIAS
ESCUELA PROFESIONAL DE ING. ELECTRÓNICA Y
TELECOMUNICACIONES

Informe Técnico – Trabajo Encargado 02

DOCENTE:

Ing. Julio Ancajima

AUTORES:

Ripa Falla, Juan Mariano

Silupu Valverde, Jose Enrique

Timana Sullon Horacio Rafael

IV CICLO

22 de mayo del 2026

Contenido

1. Objetivos del Proyecto	3
Objetivo General:	3
Objetivos Específicos:	3
2. Marco Teórico Compacto.....	3
2.1 Coeficiente de Reflexión (S11) y Resonancia.....	3
2.2 Redes Neuronales Artificiales (MLP) y Modelado Inverso.....	4
2.3 La Maldición de la Dimensionalidad y Codificación Latente.....	4
3. Hoja Técnica de las Especificaciones del Dataset.....	4
4. Pipeline del Sistema Inteligente y Metodología	5
5. Análisis de Resultados Experimentales	6
5.1 Análisis Espectral y Matriz de Correlación	6
5.2 Análisis de Convergencia.....	6
• Modelo Original (101 dimensiones)	6
• Modelo Codificado (17 dimensiones).....	6
5.3 Ventajas Computacionales de la Codificación	6
6. Respuesta a la Pregunta Principal del Trabajo	7
7. Aplicaciones en la Industria de Telecomunicaciones	7
8. Conclusiones Finales	8

1. Objetivos del Proyecto

Objetivo General:

Desarrollar, implementar y evaluar un sistema inteligente basado en Redes Neuronales Artificiales (MLP) capaz de resolver el modelo inverso de diseño de antenas, mapeando su coeficiente de reflexión espectral (S_{11}) hacia sus dimensiones físicas y geométricas estructurales.

Objetivos Específicos:

- Leer, procesar y visualizar de forma espectral curvas de coeficiente de reflexión S_{11} provenientes de bases de datos estructuradas de la IEEE en formato HDF5 (.h5).
- Analizar estadísticamente el comportamiento espectral de las antenas mediante matrices de correlación de Pearson para justificar el uso de técnicas de aprendizaje supervisado.
- Construir un pipeline robusto de entrenamiento utilizando TensorFlow/Keras que implemente una separación estricta de conjuntos de entrenamiento (train), validación interna (validation) y prueba (test), evitando el sesgo de datos (data leakage).
- Evaluar el impacto de la reducción de dimensionalidad en el rendimiento de la IA, comparando una red entrenada con el espectro original de 101 dimensiones frente a una optimizada con 17 dimensiones codificadas.
- Cuantificar las ventajas computacionales de la codificación inteligente a través del Error Cuadrático Medio (MSE), la precisión global (R^2 Score) y los tiempos de inferencia del sistema.

2. Marco Teórico Compacto

2.1 Coeficiente de Reflexión (S_{11}) y Resonancia

En ingeniería de microondas y antenas, el parámetro S_{11} representa el coeficiente de reflexión de la puerta de entrada. Mide cuánta potencia de señal es reflejada de vuelta hacia el transmisor en lugar de ser radiada al espacio libre. Su magnitud se expresa comúnmente en decibelios (dB). Un valor de S_{11} cercano a 0 dB significa que toda la energía se refleja (la antena no funciona en esa frecuencia), mientras que valles pronunciados (valores muy negativos, como -15 dB o -30 dB) indican los puntos de frecuencia de resonancia, donde la antena acopla la energía de manera óptima para la transmisión.

2.2 Redes Neuronales Artificiales (MLP) y Modelado Inverso

Un Perceptr3n Multicapa (MLP) es una arquitectura de red neuronal densa hacia adelante (Feedforward) id3nea para tareas de regresi3n no lineal complejas. En el dise1o tradicional de antenas (modelo directo), se definen los par3metros geom3tricos en un simulador electromagn3tico por mallas (como CST o HFSS) para calcular el espectro S11, demandando un tiempo computacional cr3tico de horas. El Modelado Inverso rompe este paradigma utilizando la IA: se ingresa la respuesta S11 deseada y el sistema estima instant3neamente los 8 par3metros f3sicos y geom3tricos ideales para construirla.

2.3 La Maldici3n de la Dimensionalidad y Codificaci3n Latente

Trabajar con espectros continuos de alta resoluci3n (como 101 puntos de frecuencia) introduce redundancia, ruido matem3tico y una alta carga computacional en los algoritmos de IA. La reducci3n de dimensionalidad mediante codificaci3n inteligente extrae las caracter3sticas latentes del espectro, comprimiendo la informaci3n matem3tica en un espacio de solo 17 variables esenciales. Esto estabiliza el espacio de b3squeda del optimizador, acelera la inferencia y elimina el sobreajuste (overfitting).

3. Hoja T3cnica de las Especificaciones del Dataset

A continuaci3n, se tabula la estructura y dimensiones de los archivos HDF5 utilizados. Se aplic3 una pol3tica estricta de divisi3n de datos independientes para el entrenamiento y la validaci3n final del sistema inteligente:

Nombre del Conjunto de Datos (Dataset Key)	Dimensi3n / Matriz (Shape)	Descripci3n T3cnica del Vector
S11_combine_train	(138249, 101)	Curvas S11 originales (101 puntos de frecuencia) para entrenamiento.
S11_combine_test	(59250, 101)	Curvas S11 originales (101 puntos de frecuencia) reservadas para prueba.
S11_encode_train	(138249, 17)	Curvas S11 reducidas/codificadas a 17

		dimensiones espaciales para entrenamiento.
S11_encode_test	(59250, 17)	Curvas S11 reducidas/codificadas a 17 dimensiones espaciales reservadas para prueba.
final_params_combine_train	(138249, 8)	8 Parámetros geométricos reales correspondientes a las muestras de entrenamiento.
final_params_combine_test	(59250, 8)	8 Parámetros geométricos reales correspondientes a las muestras de prueba.

4. Pipeline del Sistema Inteligente y Metodología

El flujo de trabajo se implementó íntegramente en Python utilizando TensorFlow y Keras. Con el fin de generar una comparativa estadística y técnica totalmente equitativa y transparente, se diseñaron dos modelos con la misma topología interna, alternando exclusivamente la dimensión de la capa de entrada:

- **Capa de Entrada (Input Layer):** Adaptable dinámicamente según el experimento (101 neuronas para el Modelo Original; 17 neuronas para el Modelo Codificado).
- **Capas Ocultas (Hidden Layers):** Estructura secuencial profunda de 3 capas densas (Dense) totalmente conectadas con 128, 64 y 32 neuronas consecutivas. Se implementó la función de activación no lineal ReLU (Rectified Linear Unit) para permitir el aprendizaje de los valles de resonancia.
- **Capa de Salida (Output Layer):** Una capa de tipo Dense con 8 neuronas y función de activación puramente lineal, encargada de predecir de forma simultánea los valores continuos de los 8 parámetros físicos de la antena.
- **Compilación y Regularización:** Ambas redes fueron entrenadas utilizando el optimizador Adam junto a la función de pérdida del Error Cuadrático Medio (MSE). Durante el proceso, un 20% del conjunto de entrenamiento fue retenido estrictamente como set de validación local interna, garantizando un monitoreo limpio sin mezclar bajo ninguna circunstancia el conjunto de prueba (test).

5. Análisis de Resultados Experimentales

5.1 Análisis Espectral y Matriz de Correlación

Al visualizar el espectro original, se constataron patrones geométricos claros. Las curvas muestran frecuencias de corte y valles de sintonización específicos. Matemáticamente, el mapa de calor (Heatmap) de correlación de Pearson demostró que la geometría altera de forma predecible el espectro. Por ejemplo, el Param_2 exhibe una correlación positiva moderada de 0.29 con las frecuencias altas, confirmando que las variaciones físicas en la estructura de la antena tienen un impacto directo y no aleatorio sobre su respuesta en frecuencia, validando el uso de redes neuronales.

5.2 Análisis de Convergencia

La fase de entrenamiento arrojó curvas de convergencia marcadamente opuestas, aportando evidencia científica clave:

- **Modelo Original (101 dimensiones):** El aprendizaje demostró ser altamente inestable. El error de validación interna (Val Loss) experimentó oscilaciones recurrentes y un estancamiento prematuro en un valor elevado (cercano a 226). Esto evidencia la presencia de redundancia y ruido matemático provocado por la alta dimensionalidad, dificultando que el optimizador encuentre mínimos globales.
- **Modelo Codificado (17 dimensiones):** Al usar la representación reducida, la función de pérdida decreció de forma suave, monótona y óptima desde la primera época. Las curvas de Train Loss y Val Loss convergieron en perfecta armonía, estabilizándose en un MSE drásticamente menor (cercano a 28) y erradicando por completo el sobreajuste.

5.3 Ventajas Computacionales de la Codificación

Al reducir la dimensión de entrada en un 83.1% (de 101 a 17 columnas), el volumen de tensores procesados disminuye radicalmente. Esto se traduce de forma directa en las siguientes ventajas técnicas verificadas en los experimentos:

- Reducción masiva del Error Cuadrático Medio (MSE), logrando predicciones de parámetros mucho más exactas.
- Aceleración del tiempo de inferencia total sobre las 59,250 muestras de prueba, optimizando el costo computacional.
- Menor huella de memoria RAM y operaciones de coma flotante, habilitando la portabilidad del modelo hacia entornos con hardware limitado.

6. Respuesta a la Pregunta Principal del Trabajo

Pregunta de la Asignación:

¿Puede una representación comprimida de la respuesta (S11) mantener suficiente información electromagnética para permitir el diseño y optimización inteligente de antenas mediante técnicas modernas de Inteligencia Artificial?

Respuesta Científica y Experimental: Sí, de forma categórica. Los resultados experimentales demuestran firmemente que la representación codificada de 17 dimensiones no solo retiene la información electromagnética crítica de la antena, sino que actúa de forma activa como un extractor de características esenciales e indispensables. Al eliminar las correlaciones redundantes y el ruido inherente de los 101 puntos de frecuencia del espectro continuo, se simplifica el espacio de búsqueda matemático. Esto permite que el algoritmo inteligente converja hacia soluciones geométricas drásticamente más precisas, requiriendo una fracción del tiempo de procesamiento informático y optimizando el rendimiento de la red neuronal.

7. Aplicaciones en la Industria de Telecomunicaciones

Este sistema inteligente de modelado inverso y compresión de características abre una amplia gama de aplicaciones disruptivas en el sector de la ingeniería de radiofrecuencia moderna:

- **Sistemas de Comunicación 5G/6G:** Habilita la sintonización instantánea de arreglos de antenas inteligentes (Phased Arrays) utilizados en estaciones base. La IA calcula y compensa los desfases y dimensiones necesarias en microsegundos para dirigir haces de energía de forma dinámica hacia los usuarios.
- **Antenas Reconfigurables Autónomas:** Gracias a un tiempo de inferencia ultra bajo, el modelo puede integrarse en el firmware de sistemas de comunicación en tiempo real. Esto permite que la antena autoevalúe su respuesta frente a interferencias externas y mute o adapte sus propiedades físicas y eléctricas de manera automatizada.
- **Optimización Electromagnética y Gemelos Digitales RF:** Reemplaza el uso exhaustivo de softwares de simulación en 3D basados en mallas densas que tardan horas en resolver las ecuaciones de Maxwell para un solo prototipo. La red neuronal entrenada actúa como un 'Gemelo Virtual' de alta fidelidad, prediciendo respuestas físicas exactas en milisegundos, reduciendo los costos de manufactura y acelerando drásticamente los ciclos de diseño industrial.

8. Conclusiones Finales

- Se resolvió con éxito el modelo inverso de diseño de antenas utilizando redes neuronales artificiales densas secuenciales (MLP) sobre un dataset masivo de la IEEE con más de 138,000 registros, logrando un pipeline robusto y escalable.
- Se demostró experimentalmente que la maldición de la dimensionalidad afecta negativamente el entrenamiento en el espectro completo de 101 variables, provocando inestabilidad en el optimizador y un estancamiento en pérdidas elevadas (MSE de 226).
- La reducción de dimensionalidad a 17 variables latentes codificadas filtró eficientemente el ruido matemático y la redundancia espectral, logrando una convergencia óptima, limpia y un error drásticamente menor (MSE de 28).
- La codificación inteligente proporciona una ventaja computacional disruptiva en términos de velocidad (tiempo de inferencia optimizado) y ligereza de datos, permitiendo que arquitecturas de IA compactas superen a modelos complejos expuestos a datos redundantes.
- El enfoque implementado valida el concepto de Gemelos Digitales en Radiofrecuencia (RF), sentando las bases tecnológicas para el diseño inmediato y automatizado de componentes críticos en redes de telecomunicaciones de última generación como 5G.